

Classificação de Risco de Câncer Cervical

Relatório Técnico Consolidado

EDA · Pré-processamento · Modelagem · Calibração de Limiar · Interpretabilidade

Dataset: Cervical Cancer (Risk Factors) — UCI Machine Learning Repository

Repositório do projeto: <https://github.com/talesgomes/fiap-ia-devs-tech-challenge-fase1>

EQUIPE

Nome	RM
Daniel Henrique Soter de Souza	rm376376
Otávio Braga Goulart	rm376980
Thales Gomes Targino	rm376365

Sumário

1. Introdução
2. Discussões da Análise Exploratória (EDA)
3. Estratégias de Pré-processamento
4. Modelos Usados e Por Quê
5. Resultados e Interpretação dos Dados
6. Limitações Gerais e Trabalhos Futuros

1. Introdução

O câncer cervical é uma das principais causas de morte por câncer entre mulheres em diversas regiões do mundo, mas é uma doença altamente evitável quando detectada precocemente por meio de exames de rastreio (Papanicolau, colposcopia, biópsia, entre outros). A literatura médica já identificou há décadas um conjunto de fatores de risco comportamentais e clínicos associados à doença — idade, comportamento sexual e reprodutivo, tabagismo, uso de contraceptivos e histórico de infecções sexualmente transmissíveis (DSTs), especialmente o HPV. O desafio prático está em como combinar esses fatores para estimar o risco individual de cada paciente de forma útil para a triagem clínica.

Este projeto utiliza o dataset público [Cervical Cancer \(Risk Factors\)](#), do UCI Machine Learning Repository, que reúne 858 registros de pacientes com variáveis demográficas, comportamentais e clínicas, além dos resultados de quatro exames de rastreio distintos — entre eles a variável-alvo deste projeto, `Biopsy` (resultado da biópsia: positivo ou negativo).

Objetivo do projeto: construir e avaliar criticamente um pipeline de classificação de risco de biópsia positiva, cobrindo todo o ciclo de um projeto de Machine Learning aplicado — da análise exploratória a uma discussão honesta sobre a real viabilidade de uso desse tipo de modelo em um cenário clínico. O trabalho foi estruturado em cinco notebooks sequenciais, cada um com escopo bem definido e suas próprias decisões e limitações documentadas. Este relatório consolida os principais achados e decisões de cada etapa de forma sintética; o detalhamento completo de cada uma — código, gráficos e justificativas — está disponível nos notebooks, em `/notebooks/`.

Repositório do projeto: <https://github.com/thalesgomes/fiap-ia-devs-tech-challenge-fase1>

2. Discussões da Análise Exploratória (EDA)

A análise exploratória (notebook `01_eda.ipynb`) teve como objetivo entender a qualidade dos dados e identificar padrões relevantes antes de qualquer decisão de modelagem. Os principais achados foram:

Qualidade dos dados

O dataset original representa valores ausentes com o caractere `"?"`. Após o tratamento correto desses valores como nulos, observou-se que duas colunas (`STDs: Time since first diagnosis` e `STDs: Time since last diagnosis`) têm mais de 90% de dados faltantes, praticamente inviabilizando seu uso. As demais colunas com valores ausentes variam entre ~1% (ex.: `First sexual intercourse`) e ~14% (ex.: `IUD`, `Hormonal Contraceptives` e o grupo de variáveis de DSTs) — uma proporção baixa o suficiente para justificar imputação em vez de descarte.

Desbalanceamento de classes

A variável-alvo `Biopsy` é fortemente desbalanceada: apenas 55 dos 858 pacientes (6,41%) têm biópsia positiva. Esse desbalanceamento orientou decisões em praticamente todas as etapas seguintes do projeto — da escolha das métricas de avaliação ao uso de técnicas de balanceamento na modelagem.




Figura 1. Distribuição da variável-alvo (Biopsy) no dataset completo (858 pacientes).

Risco de vazamento de dados (data leakage)

A análise de correlação revelou que `Hinselmann`, `Schiller` e `Citology` (outros exames de rastreamento da mesma condição) e os campos `Dx`, `Dx:Cancer`, `Dx:CIN` e `Dx:HPV` (diagnósticos) são as variáveis mais fortemente correlacionadas com `Biopsy` (correlações de até 0,73). Isso não é coincidência: são formas diferentes de investigar ou registrar a mesma condição clínica. Usá-las como preditoras faria o modelo parecer artificialmente bom, mas não

refletiria um cenário real de triagem, no qual essas informações normalmente não estariam disponíveis antes da biópsia.




Figura 2. Correlação de cada variável com a variável-alvo (Biopsy). As variáveis no topo (exames e diagnósticos) foram excluídas do conjunto preditor por risco de vazamento — ver Seção 3.

Padrões de saúde e segurança feminina

Uso de contraceptivos hormonais/DIU, tabagismo e histórico de DSTs mostraram alguma associação com Biopsy , mas nenhum fator isoladamente forte — resultado coerente com a natureza multifatorial do risco de câncer cervical descrita na literatura médica.

3. Estratégias de Pré-processamento

O pré-processamento (notebook `02_preprocessing.ipynb`) traduziu os achados da EDA em transformações concretas sobre os dados:

- **Valores ausentes:** as duas colunas com mais de 90% de nulos foram removidas. As demais foram imputadas — **mediana** para variáveis numéricas (mais robusta a distribuições assimétricas) e **moda** para variáveis binárias/categóricas — sempre ajustando o imputador apenas no conjunto de treino, para não vaziar informação do teste.
- **Remoção por data leakage:** as sete variáveis identificadas na EDA (`Hinselmann` , `Schiller` , `Citology` , `Dx` , `Dx:Cancer` , `Dx:CIN` , `Dx:HPV`) foram removidas do conjunto de variáveis preditoras.
- **Assimetria e outliers:** `Number of sexual partners` e `Num of pregnancies` passaram por transformação logarítmica (`log1p`), que reduz a cauda longa dessas distribuições sem descartar nenhuma observação — ao contrário da winsorização, que corta valores extremos.
- **Padronização:** as 10 variáveis numéricas contínuas foram padronizadas (`StandardScaler` , ajustado só no treino); as 16 variáveis binárias foram mantidas como estão. Não havia variáveis categóricas de texto a codificar — o dataset já é inteiramente numérico.
- **Split treino/teste:** separação estratificada 80/20 (686 linhas de treino, 172 de teste), preservando a proporção de ~6,4% de positivos em ambos os conjuntos. O split foi feito **antes** da imputação e da padronização, para que essas etapas fossem ajustadas somente no treino.
- **Balanceamento de classes:** deliberadamente **não** aplicado nesta etapa. Balanceamento (SMOTE) é uma técnica de treino, e foi reservado para a etapa de modelagem, onde pode ser aplicado de forma controlada dentro de cada fold de validação cruzada — ver Seção 4.

4. Modelos Usados e Por Quê

Na etapa de modelagem (notebook `03_modeling.ipynb`), três classificadores foram treinados e comparados como baseline: **Regressão Logística**, **Árvore de Decisão** e **Random Forest**. Em todos os casos, o SMOTE (técnica de sobreamostragem da classe minoritária) foi aplicado **somente no treino**, e de forma correta dentro de cada fold da validação cruzada estratificada (5 folds) — evitando que exemplos sintéticos vazassem entre o fold de treino e o fold de validação, o que inflaria artificialmente as métricas.

Tabela 1. Comparação dos modelos baseline (médias em validação cruzada, 5 folds).

Modelo	F1	Recall	AUC-ROC	AUC-PR
Random Forest	0,150	0,114	0,621	0,224
Regressão Logística	0,139	0,403	0,600	0,116
Árvore de Decisão	0,195	0,228	0,577	0,107

Os três modelos discordam entre si sobre qual métrica priorizam — não há um vencedor único e óbvio. O **Random Forest** foi escolhido para ajuste de hiperparâmetros por ter a melhor **AUC-PR** média, a métrica considerada mais robusta ao desbalanceamento de classes (ao contrário da AUC-ROC, ela não é dominada pela grande quantidade de verdadeiros negativos). Após um ajuste simples via `GridSearchCV`, o modelo final ficou configurado com `n_estimators=400`, `max_depth=None`, `min_samples_leaf=1` (AUC-PR média de 0,228 em validação cruzada).

Por que a calibração de limiar foi necessária: avaliado no conjunto de teste com o limiar padrão do scikit-learn (0,5), o Random Forest final obteve F1 = 0,133, **Recall = 0,091**, AUC-ROC = 0,745 e AUC-PR = 0,213. Na prática, isso significa que o modelo captura apenas **1 dos 11 casos positivos do teste** — um resultado inaceitável em um contexto clínico, no qual um falso negativo (deixar passar um caso de risco real) é um erro muito mais grave do que um falso positivo (pedir um exame adicional). Isso motivou a etapa seguinte, dedicada exclusivamente a recalibrar esse limiar de decisão para priorizar Recall, aceitando deliberadamente mais falsos positivos em troca de menos falsos negativos.

5. Resultados e Interpretação dos Dados

Calibração do limiar de decisão

Na etapa de calibração (notebook `04_threshold_calibration.ipynb`), o modelo final foi carregado **sem retreino** e submetido a uma varredura de limiares de decisão (0,05 a 0,50, em passos de 0,05) sobre o conjunto de teste, calculando Precision, Recall e F1 para cada ponto de corte.

Critério de escolha: o maior limiar testado que ainda garantisse Recall igual ou superior a 70% — uma meta definida como uma escolha de negócio/clínica razoável, mas explicitamente arbitrária, para fins deste exercício. O limiar escolhido foi **0,10**.




Figura 3. Curvas Precision-Recall e ROC do modelo final no conjunto de teste.

Tabela 2. Random Forest final — limiar padrão vs. limiar calibrado (conjunto de teste).

Métrica	Limiar 0,5 (padrão)	Limiar 0,10 (calibrado)
Precision	0,250	0,120
Recall	0,091 (1 de 11 casos)	0,818 (9 de 11 casos)
F1	0,133	0,209

AUC-ROC (0,745) e AUC-PR (0,213) não variam com o limiar — são propriedades do modelo, não da regra de decisão aplicada sobre a probabilidade prevista.




Figura 4. Matrizes de confusão no teste — limiar padrão (0,5) vs. limiar calibrado (0,10).

O ganho em Recall é substancial (de 9% para 82%), mas o custo também: os falsos positivos sobem de 3 para 66 (de 161 pacientes sem a condição). Se o exame de acompanhamento adicional for de baixo custo e risco, essa troca tende a ser favorável no contexto clínico descrito; caso contrário, a meta de Recall exigida precisaria ser reconsiderada junto a especialistas.

Interpretabilidade: feature importance e SHAP

Na etapa final (notebook `05_interpretability.ipynb`), o modelo e o limiar calibrado foram carregados sem retreino para uma análise de interpretabilidade. As cinco variáveis mais importantes, segundo o `feature_importances_` do Random Forest, são `Num of pregnancies`, `First sexual intercourse`, `Number of sexual partners`, `Hormonal Contraceptives (years)` e `Age` — todas variáveis de exposição comportamental/reprodutiva, coerentes com os padrões já observados na EDA (Seção 2).




Figura 5. Top 15 variáveis mais importantes segundo o Random Forest.

A análise com SHAP confirmou esse padrão de forma independente: a correlação de Spearman entre o ranking de importância do Random Forest e o ranking de importância média do SHAP foi de **0,985** — uma concordância muito alta, que aumenta a confiança de que essas variáveis capturam um padrão real aprendido pelo modelo, e não um artefato de uma única técnica.




Figura 6. Impacto de cada variável nas previsões do modelo (SHAP, classe positiva), para o conjunto de teste.

Explicações individuais (SHAP local) para um verdadeiro positivo, um falso negativo e um falso positivo do teste mostraram como fatores específicos de cada paciente influenciam a previsão — útil para auditar decisões caso a caso, mas sujeito ao mesmo aviso: com apenas 11 casos positivos no teste, essas leituras individuais devem ser vistas como ilustrativas, não como conclusões generalizáveis.

O modelo pode ser usado na prática?

A discussão crítica desenvolvida no notebook `05_interpretability.ipynb` conclui, de forma direta, que **o modelo não está pronto para apoiar decisões clínicas reais** no seu estado atual. Na melhor das hipóteses, ele poderia ser considerado uma ferramenta de **priorização de casos para exame** dentro de um fluxo de triagem já existente, ou uma **segunda opinião estatística** a ser cruzada com outros exames — nunca como critério único de decisão. O médico deve manter a palavra final no diagnóstico: o modelo aprendeu padrões estatísticos de uma amostra específica, sem acesso ao histórico clínico completo da paciente nem qualquer responsabilidade sobre as consequências de um erro. Riscos concretos de uso inadequado incluem excesso de confiança em métricas medidas sobre pouquíssimos casos positivos, viés dos dados de treino (população, época e contexto de coleta específicos) e fragilidade do limiar calibrado ao ser aplicado em uma população diferente da estudada aqui.

6. Limitações Gerais e Trabalhos Futuros

Limitações consolidadas

- **Tamanho amostral pequeno:** das 858 pacientes do dataset, apenas 55 têm biópsia positiva (44 no treino, 11 no teste). Essa escassez de casos positivos torna qualquer métrica — de comparação de modelos a calibração de limiar e interpretabilidade — sensível a ruído amostral, em todas as etapas do projeto.
- **Calibração sem conjunto de validação separado:** por falta de dados suficientes para uma terceira partição, o limiar de decisão foi calibrado e avaliado no mesmo conjunto de teste — um compromisso pragmático, reportado com transparência, mas que idealmente seria evitado com mais dados disponíveis.
- **SMOTE vs. `class_weight`** : o projeto usou SMOTE, aplicado corretamente dentro da validação cruzada, mas não comparou essa abordagem com a alternativa de ponderar as classes diretamente no classificador (`class_weight="balanced"`) — uma comparação que fica como sugestão de trabalho futuro.
- **Meta de Recall arbitrária:** o piso de 70% de Recall usado na calibração de limiar foi uma escolha razoável, mas técnica, feita para fins deste exercício. Em um cenário real, esse número deveria ser definido em conjunto com profissionais de saúde, considerando o custo real dos exames de acompanhamento.
- **Comparação incompleta entre modelos:** a Regressão Logística, que teve o melhor Recall entre os baseline (~40% em validação cruzada), não pôde ser reavaliada sob o limiar calibrado por não ter sido exportada como artefato treinado na etapa de modelagem.
- **Sinais de overfitting:** o Random Forest final (`max_depth=None`) mostrou desempenho no treino bem superior ao desempenho no teste — um indício de que o modelo memoriza parte do treino, não totalmente corrigido nesta fase do projeto.

Trabalhos futuros (fora do escopo desta fase)

- Validação externa do modelo em outras populações/bases de dados.
- Coleta de mais dados, especialmente mais casos positivos de biópsia.
- Comparação sistemática entre SMOTE e `class_weight="balanced"` .
- Exportação e comparação da Regressão Logística sob o limiar calibrado.
- Calibração do limiar de decisão com um conjunto de validação genuinamente separado do teste, e validação da meta de Recall com especialistas clínicos.
- Interpretabilidade adicional e preparação para produção (deploy, API, monitoramento de performance ao longo do tempo) — explicitamente fora do escopo de todas as etapas realizadas até aqui.